# MACHINE LEARNING CANVAS

Designed for: **TC5061** Designed by: **Equipo 51** Date: **17/Oct/26** Iteration: **1** .

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

**OWNML.CO**

## PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

**P1:** Regresión: predecir el número de viajes iniciados por estación en intervalos de 1 hora. Para el modelo desarrollado, al inicio de cada hora se estima la demanda de la hora siguiente utilizando únicamente información observada hasta el cierre de la hora anterior. La entidad es estación–hora y el resultado observado es el conteo de viajes iniciados en ese intervalo. Como extensión futura, el horizonte podría ampliarse de 1 hasta 24 horas.

**P2:** Clasificación multiclase para estimar, por estación-hora, el riesgo operativo durante las siguientes 2 horas. Las clases son operación normal, riesgo de vaciado y riesgo de saturación. Como los datos no incluyen inventario histórico, el objetivo se aproxima mediante la suma del flujo neto de las horas t+1 y t+2, normalizada por la capacidad de la estación. Los umbrales 10 % y 90 % se calcularon únicamente con entrenamiento.

**P3:** Clustering: agrupar estaciones según patrones históricos de utilización y características espaciales. La entidad es la estación y el resultado es la asignación a un cluster que represente un patrón de uso similar. Al ser aprendizaje no supervisado, no existe un horizonte de predicción equivalente al de P1/P2.

## DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

**P1:** utilizar las estimaciones de demanda para anticipar estaciones con alta demanda y planificar la distribución de bicicletas y las rutas de rebalanceo antes de los periodos de mayor utilización.

**P2:** utilizar las clases de riesgo para priorizar estaciones que requieran intervención, retirando bicicletas de estaciones con riesgo de saturación y redistribuyéndolas hacia estaciones con riesgo de vaciado. Las predicciones orientan la prioridad operativa, pero no sustituyen la decisión del personal responsable.

**P3:** utilizar los grupos de estaciones para identificar patrones funcionales y espaciales que apoyen decisiones de ampliación de capacidad, ubicación de nuevas estaciones y estrategias estructurales de balanceo.

## VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

**P1:** apoyar al personal responsable de la operación y logística de MiBici mediante pronósticos de demanda por estación que permitan anticipar necesidades de redistribución.

**P2:** apoyar al equipo de rebalanceo mediante la identificación anticipada de estaciones con riesgo de vaciado o saturación, permitiendo priorizar intervenciones.

**P3:** apoyar a los responsables de planeación y expansión del sistema mediante la identificación de estaciones con patrones de uso similares y su distribución geográfica.

La solución podría presentar predicciones, niveles de riesgo y clusters mediante reportes o visualizaciones geoespaciales generadas periódicamente.

## DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Datos de enero de 2024 a septiembre de 2026 (33 meses completos). La ingesta automatizada mediante dataset.py descarga los archivos mensuales de viajes y la nomenclatura de estaciones, normaliza esquemas, codificación y fechas, elimina duplicados exactos, almacena los datos procesados en formato Parquet y genera un manifiesto para el versionado reproducible de los datos.

Se utilizaron 12,539,260 viajes procesados y de 473 estaciones observadas como origen se utilizaron 471.

## DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Portal de datos abiertos de MiBici:

Archivos CSV mensuales de viajes (datos_abiertos_AAAA_MM.csv), que contienen información del viaje, usuario, fechas/horas y estaciones de origen y destino.

Archivo de nomenclatura de estaciones (nomenclatura_2026_09.csv), utilizado como referencia de las estaciones disponibles y sus atributos, incluyendo identificador, nombre, latitud, longitud y capacidad.

De los viajes se leen únicamente las fechas y estaciones de origen y destino; de la nomenclatura se utilizan identificador, capacidad, latitud y longitud. **No** se usan identificadores ni atributos personales de las personas usuarias.

## IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

**P1:** Se evaluará el beneficio de anticipar correctamente la demanda y el costo operativo de subestimarla o sobreestimarla. Una subestimación puede incrementar el riesgo de falta de bicicletas, mientras que una sobreestimación puede provocar rebalanceos innecesarios. Además de las métricas globales, se revisará el desempeño en estaciones establecidas y estaciones nuevas (cold-start), ya que estas últimas disponen de menor historial y representan una condición más desafiante para el modelo.

**P2:** Los errores más costosos serán los falsos negativos en las clases críticas, ya que no detectar una estación con riesgo de vaciado o saturación puede impedir una intervención oportuna. Los falsos positivos pueden generar desplazamientos innecesarios de las cuadrillas de rebalanceo.

**P3:** Se evaluará si los clusters son consistentes, diferenciables e interpretables en términos de patrones de uso y distribución espacial; agrupaciones poco estables o sin significado operativo tendrían bajo valor para planeación.

**Criterio de aceptación:** Las soluciones deberán superar sus baselines y mostrar desempeño estable. Se revisarán diferencias de desempeño entre estaciones/zonas.

**Equidad:** Se revisará el desempeño entre estaciones y zonas para identificar si la solución presenta diferencias sistemáticas que puedan perjudicar áreas con menor volumen de viajes.

## MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

**P1:** Inferencia horaria. Al inicio de cada hora se genera una estimación del número de viajes que se iniciarán por estación durante la hora siguiente, utilizando únicamente información disponible hasta el cierre de la hora anterior. Como extensión futura, el horizonte podría ampliarse para generar pronósticos de las siguientes 24 h.

**P2:** Inferencia batch horaria para estimar riesgo de vaciado/saturación en las siguientes 2 h; el procesamiento debe finalizar dentro del intervalo de actualización.

**P3:** Recalculo periódico (propuesta: trimestral) de clusters con datos históricos consolidados; no requiere tiempo real.

**Recursos:** El procesamiento se realizará inicialmente en infraestructura local mediante Python y las herramientas definidas en el repositorio.

La arquitectura podrá escalarse posteriormente si el volumen de datos o los tiempos de ejecución lo requieren.

## BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

**P1:** Se desarrolló un modelo global de regresión para estimar la demanda horaria de todas las estaciones. Se utilizó como baseline un modelo estacional ingenuo basado en la demanda observada 168 horas antes (lag_168) y como modelo candidato un CatBoostRegressor. El modelo final utiliza 200 iteraciones, profundidad 6, learning rate de 0.1 y semilla 42. En validación, CatBoost obtuvo MAE = 0.7972 y RMSE = 1.4458, superando al baseline estacional (MAE = 0.9979; RMSE = 2.0318).

**P2:** Se comparó un DummyClassifier estratificado con una regresión logística global usando class_weight="balanced", C=1.0, solver saga, 100 iteraciones y semilla 777. La selección se realizó con F1 macro de validación. La regresión logística fue seleccionada y obtuvo en prueba F1 macro de 0.4041, recall de vaciado de 0.5331, recall de saturación de 0.5237 y G-Mean de 0.5390.

**P3:** Un modelo de clustering para segmentar las estaciones de acuerdo con sus patrones históricos de utilización y características espaciales.

Entrenamiento offline con datos de enero de 2024 a septiembre de 2026. Para P1 se utilizó una partición temporal: entrenamiento hasta diciembre de 2025, validación de enero a abril de 2026 y prueba de mayo a septiembre de 2026. El conjunto de prueba se utilizó únicamente después de seleccionar el modelo final. P2/P3 podrán definir su esquema de reentrenamiento de acuerdo con sus necesidades.

Feature engineering, entrenamiento y evaluación en Python; experimentos registrados en MLflow con parámetros, métricas, artefactos, versión de datos y commit de Git.

## FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

**P1:** variables de calendario (hour_of_day, day_of_week, is_weekend, month); identificador de estación (station_id); rezagos históricos de demanda (lag_1, lag_24, lag_168); medias móviles de las 3 y 24 horas anteriores (rolling_mean_3h, rolling_mean_24h); y cantidad de horas de historial disponible (history_hours). Las medias móviles se calculan después de desplazar la serie una hora para evitar incorporar información del objetivo actual.

**P2:** Se utilizan 17 características: estación, capacidad, latitud, longitud, hora, día de la semana, mes, fin de semana, entradas y salidas de la hora anterior, rezagos del flujo neto de 1, 2 y 24 horas, y promedios históricos de 3 y 24 horas. Todos los rezagos y promedios se desplazan para no usar la hora actual ni información futura.

**P3:** perfiles horarios promedio de entradas/salidas, patrones entre días laborales y fines de semana, ratios entrada/salida, volumen y variabilidad de uso, capacidad y coordenadas geográficas. Las variables serán agregadas y normalizadas según la tarea.

Todas las features predictivas se construirán exclusivamente con información disponible hasta el momento de predicción.

## MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business?
How often should they be reviewed?

**P1:** monitorear MAE y RMSE globales, así como el error por estación, franja horaria y tipo de estación (establecida o cold-start). También se vigilarán cambios en la distribución de la demanda y de las variables de entrada que puedan indicar data drift. Un deterioro sostenido del desempeño o cambios significativos en la distribución de los datos motivarán la revisión y posible reentrenamiento del modelo.

**P2:** Monitorear F1 macro, recall de riesgo de vaciado, recall de riesgo de saturación, G-Mean, matriz de confusión y distribución de predicciones. También revisar cambios en las proporciones de las clases y el desempeño por estación o zona. Un deterioro sostenido motivará la revisión de datos, umbrales y posible reentrenamiento.

**P3:** Silhouette Score, Davies-Bouldin, distribución y estabilidad de clusters.

Como KPIs operativos, evaluar disponibilidad de bicicletas/anclajes y efectividad del rebalanceo. P1/P2 se revisarán al incorporar nuevos datos y antes de actualizar modelos; P3, al recalcular los clusters.

Cambios significativos de desempeño o distribución motivarán revisión y posible reentrenamiento.